
分类问题视角下的 AdaBoost 算法

December 25, 2025

AdaBoost 模型结构

adaboost 模型介绍

- AdaBoost 是一种典型的提升（Boosting）型集成学习框架，其核心思想是：**通过多轮训练、聚焦难样本，把一群“弱学习器”提升为一个“强学习器”。**
- 在每一轮中，AdaBoost 都会为总模型增加一个新的学习器，直到模型的弱学习器个数达到预先指定的值。
- 训练新学习器时，根据上一轮的推理结果在同一训练集上**重新分配样本权重**，使新的弱学习器更加关注上一轮中被分错或“难学”的样本。
- 各轮得到的弱学习器本身能力都比较弱，但在最后通过加权组合（加权投票或加权求和），形成一个整体性能更高、泛化能力更强的强学习器。
- AdaBoost 不限定弱学习器的具体形式（如决策树桩、小深度决策树等），因此可以看作一个**通用的、可移植的集成学习框架**。

模型结构图

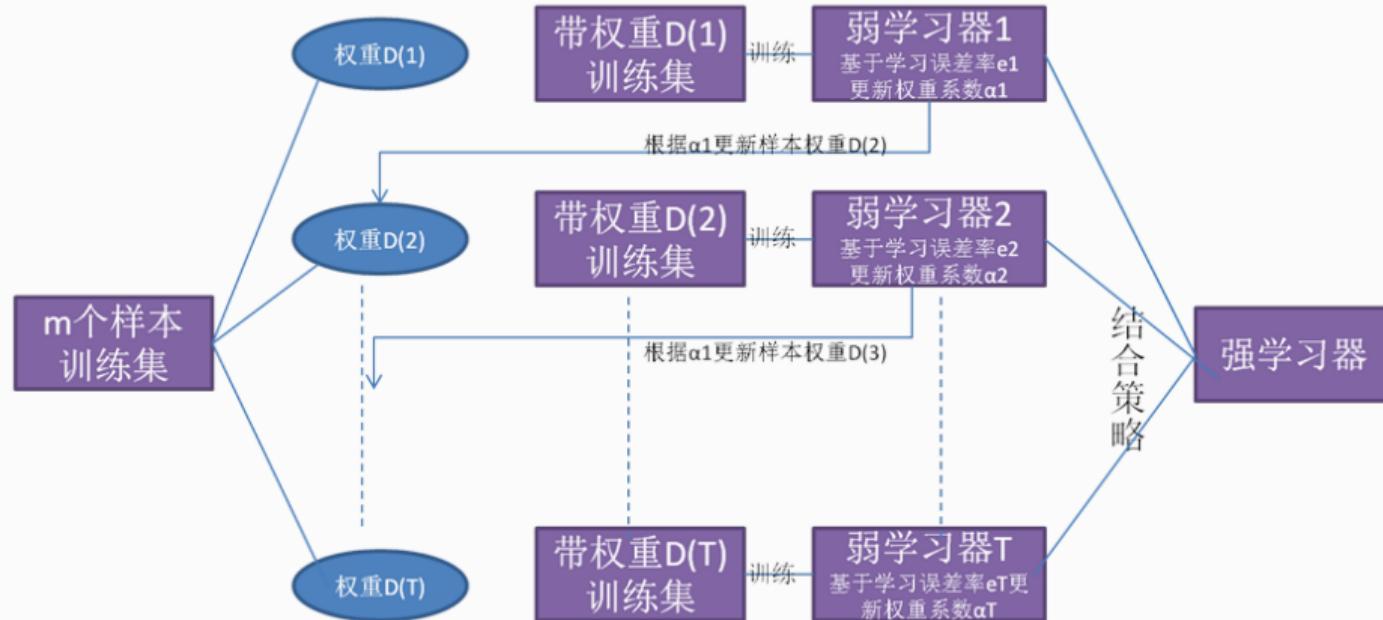


Figure 1. AdaBoost 模型结构图

模型计算流程

假设训练集包含 m 个样本 $\{(x_i, y_i), \dots, (x_m, y_m)\}$ 。

第 1 个学习器直接由初始权重的样本训练即可

不失一般性地，假设现在训练已经进行到第 t 轮。 $(t = 2, \dots, T)$

记第 $t - 1$ 个学习器在样本 x 上的预测结果为 $h_{t-1}(x)$ 。

设训练第 $t - 1$ 个弱学习器所使用的样本权重为

$$D_t = \{\omega_{t-1,1}, \dots, \omega_{t-1,m}\}, \quad \sum_{i=1}^m \omega_{t-1,i} = 1.$$

模型计算流程: 学习器权重

则第 $t - 1$ 轮弱学习器的加权错误率为

$$\varepsilon_{t-1} = \sum_{i=1}^m \omega_{t-1,i} \mathbf{1}\{h_{t-1}(x_i) \neq y_i\}.$$

第 $t - 1$ 个弱学习器的投票权重为

$$\alpha_{t-1} = \frac{1}{2} \left(\frac{1 - \varepsilon_{t-1}}{\varepsilon_{t-1}} \right)$$

模型计算流程：样本权重更新

1. 计算系数

$$\beta_{t-1} = \frac{\varepsilon_{t-1}}{1 - \varepsilon_{t-1}}, \quad 0 < \beta_{t-1} < 1.$$

2. 先得到更新后的未归一化权重

$$\tilde{\omega}_{t,i} = \omega_{t-1,i} \beta_{t-1}^{1 - \mathbf{1}\{h_{t-1}(x_i) \neq y_i\}}, \quad i = 1, \dots, m.$$

3. 再将其归一化，得到第 t 轮的权重分布

$$\omega_{t,i} = \frac{\tilde{\omega}_{t,i}}{\sum_{j=1}^m \tilde{\omega}_{t,j}}.$$

4. 由得到的新样本权重训练集训练得到第 t 个弱学习器

模型计算流程：样本权重更新

第 t 轮：直观理解：

$$\begin{cases} h_{t-1}(x_i) = y_i \Rightarrow \tilde{\omega}_{t,i} = \omega_{t-1,i} \beta_{t-1} & (\text{分对：权重减小}) \\ h_{t-1}(x_i) \neq y_i \Rightarrow \tilde{\omega}_{t,i} = \omega_{t-1,i} & (\text{分错：权重不变，归一化后相对增大}) \end{cases}$$

这意味着模型会不断给难以分类的样本点增加权重，而这些难分类的点可能是数据中的噪声/离群点，可能导致模型在中后期过拟合。

收敛性

AdaBoost 的训练误差界

设：

- 第 t 轮弱学习器的加权错误率为 ε_t ；
- 最终强分类器为 h_f ，其在训练分布 D 下的错误率为

$$\varepsilon = \Pr_{i \sim D} [h_f(x_i) \neq y_i].$$

AdaBoost 的训练误差界

训练误差上界

$$\varepsilon \leq 2^T \prod_{t=1}^T \sqrt{\varepsilon_t(1 - \varepsilon_t)}.$$

引入第 t 轮的“优势”(edge)：比随机猜测强的部分

$$\gamma_t = \frac{1}{2} - \varepsilon_t,$$

则上界可以改写为

$$\varepsilon \leq \prod_{t=1}^T \sqrt{1 - 4\gamma_t^2} = \exp\left(-\sum_{t=1}^T \text{KL}\left(\frac{1}{2} \parallel \frac{1}{2} - \gamma_t\right)\right) \leq \exp\left(-2 \sum_{t=1}^T \gamma_t^2\right).$$

AdaBoost 的训练误差界

特殊情形：若所有弱学习器的错误率都相同， $\varepsilon_t = \frac{1}{2} - \gamma$ ($\gamma > 0$)，则

$$\varepsilon \leq (1 - 4\gamma^2)^{T/2} = \exp(-T \cdot \text{KL}(\frac{1}{2} \parallel \frac{1}{2} - \gamma)) \leq \exp(-2T\gamma^2).$$

结论：只要每一轮的弱学习器都略好于随机猜测 ($\gamma_t > 0$)，AdaBoost 在训练集上的错误率会随轮数 T 指数级下降。

收敛性证明

引理：训练误差界受限于归一化因子之积。

$$\frac{1}{m} \sum_{i=1}^m \exp(-y_i f(x_i)) = \prod_{t=1}^T Z_t.$$

$$Z_t = \sum_{y_i=h_t(x_i)} \omega_{ti} e^{-\alpha_t} + \sum_{y_i \neq h_t(x_i)} \omega_{ti} e^{\alpha_t} = (1 - \varepsilon_t) e^{-\alpha_t} + \varepsilon_t e^{\alpha_t}$$

通过求导计算得到 Z_t 的极小值：

$$Z_t = 2\sqrt{\varepsilon_t(1 - \varepsilon_t)} = \sqrt{1 - 4\gamma_t^2}$$

从而得证：

$$\varepsilon_{train} \leq \prod_{t=1}^T \sqrt{1 - 4\gamma_t^2} = \exp\left(-\sum_{t=1}^T \text{KL}\left(\frac{1}{2} \parallel \frac{1}{2} - \gamma_t\right)\right) \leq \exp\left(-2 \sum_{t=1}^T \gamma_t^2\right).$$

总结与展望

AdaBoost 优缺点总结

优点：

- **泛化能力强**: 在许多问题上不易过拟合 (Margin 理论)。
- **参数少**: 原始算法几乎无需调参。
- **通用性**: 可与任何弱学习器结合。

缺点：

- **对噪声敏感**: 异常值权重会被过度放大 (本次实验重点验证)。
- **串行训练**: 难以并行化, 训练速度较慢。

经典应用: Viola-Jones 人脸检测框架 (基于 Haar 特征 + AdaBoost 级联)。

任务：手写数字识别

任务

核心目标:

训练一个 AdaBoost 分类器, 对手写数字图片进行分类。

这是一个多分类 (十类) 问题。

数据集及数据处理

数据集:

- 使用 MNIST 数据集，按照 8：2 切分训练集和测试集，
- 在 MNIST 测试集和课程提供的手写图片两组数据上分别测试。

数据预处理:

- 所有图片转化为黑底白字
- 按照包含该数字的最小正方形进行切割
- 使用 cv2.resize 方法将图片缩放至 20x20
- 将数字图片嵌入到 28x28 的纯黑色背景

数据集及数据处理

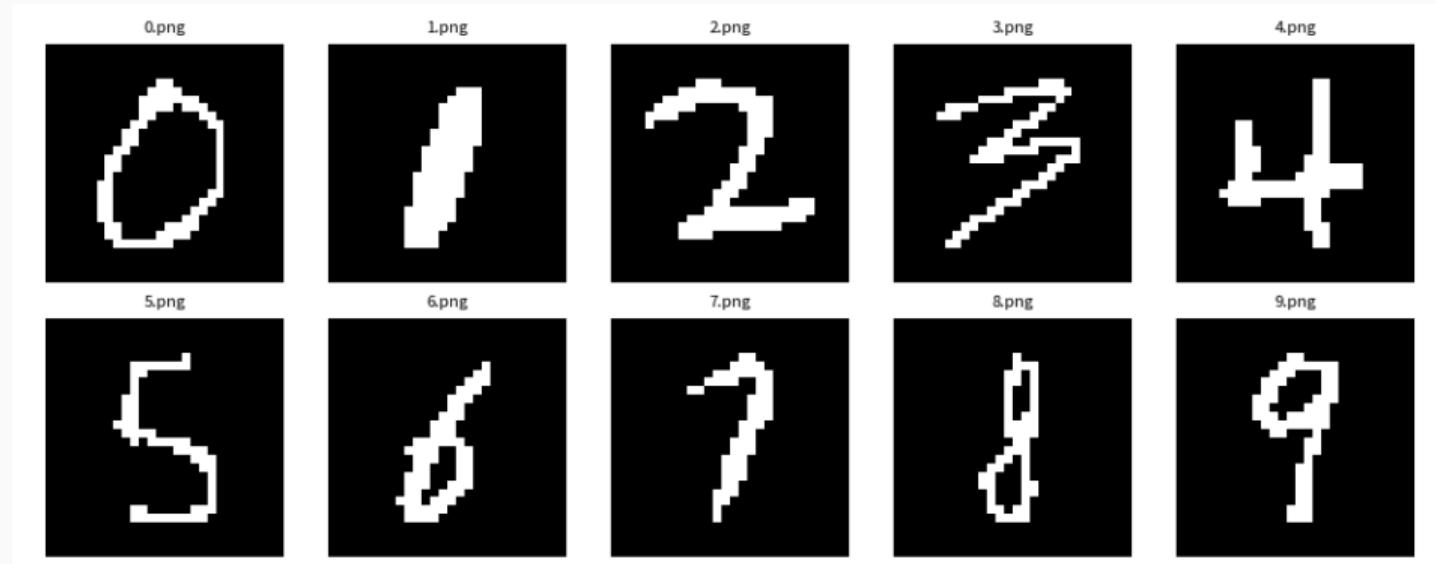


Figure 2. 预处理后数据示意图

数据集及数据处理

特征提取方法：

- 原始图片，`reshape` 为 (784,) 一维向量
- HOG
- Hu 不变矩

目标：

- 对比原始特征和提取特征的聚类效果，证明提取特征的有效性
- 提升风格迁移泛化能力

聚类与可视化：

- 对不同风格数据集的特征进行聚类和可视化，呈现分布差异

AdaLab：AdaBoost 实验园地

AdaLab 是一个面向研究的 AdaBoost 实验园地，通过端到端的实验框架支持 AdaBoost 算法的过拟合行为、泛化能力与鲁棒性特征的系统性研究。项目提供了 Python 实验框架与 CLI 工具，支持通过 JSON 配置文件驱动实验流程，实现零代码运行实验适用于算法分析、实验复现与对比研究。

- 端到端实验框架从训练、评估到可视化，所有步骤都可以通过 JSON 配置文件驱动。
- AdaBoost 核心机制可观测支持样本权重、噪声样本与干净样本权重、弱分类器 alpha 等的精细监控。
- 鲁棒性研究的数据处理模块包括特征提取（HOG、Hu 不变矩）和多种图像扰动方式（噪声、破坏、变形等）。
- CLI 驱动，零代码运行提供统一的 `adalab` 命令行工具，适合批量实验管理与脚本化操作。
- 可选配套可视化模块独立的 `adalab_viz` 包，用于结构化可视化实验结果。

AdaLab 使用方法与常见运行模式

```
Look 23
> adalab -h
usage: adalab [-h] --config CONFIG [--experiments-dir EXPERIMENTS_DIR]
               [--course-folder COURSE_FOLDER] [--viz | --viz-only]

AdaLab experiment runner (CLI)

options:
-h, --help            show this help message and exit
--config CONFIG        Path to json config file
--experiments-dir EXPERIMENTS_DIR
                      Base directory that stores experiment runs (default:
                      experiments/)
--course-folder COURSE_FOLDER
                      Course test folder used in evaluation (default:
                      ./data/test_images)
--viz                 Train + eval + visualize after training (requires
                      use_monitor=true)
--viz-only            Skip training; load existing experiment results then
                      eval + visualize
```

Figure 3.预处理后数据示意图

任务：手写数字识别

实验结果展示

AdaBoost 参数选择

参数	值
max_depth	3
max_features	0.3
criterion	entropy
random_state	42
n_estimators	500
learning_rate	0.5

Table 1.训练参数

原始图片

数据集	准确率	精度 (宏平均)	召回率 (宏平均)	F1 值 (宏平均)
MNIST	0.9184	0.9196	0.9180	0.9182
课程数据集	0.6	0.4	0.6	0.4667

Table 2.模型在 MNIST 和课程数据集上的测试结果

Hu 不变矩

数据集	准确率	精度 (宏平均)	召回率 (宏平均)	F1 值 (宏平均)
MNIST	0.5208	0.5017	0.5113	0.5038
课程数据集	0.4	0.2333	0.4	0.2833

Table 3.模型在 MNIST 和课程数据集上的测试结果

理想模型数据展示 (HOG)

参数	值
orientations	9
pixels_per_cell	[4, 4]
cells_per_block	[2, 2]

Table 4.HOG 特征提取参数

数据集	准确率	精度 (宏平均)	召回率 (宏平均)	F1 值 (宏平均)
MNIST	0.958	0.9581	0.9578	0.9579
课程数据集	0.6	0.525	0.6	0.54

Table 5.模型在 MNIST 和课程数据集上的测试结果

任务：手写数字识别

鲁棒性与误差分析

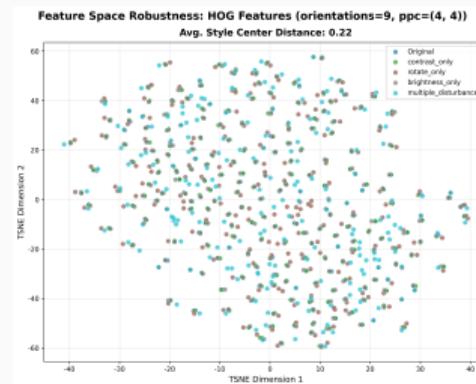
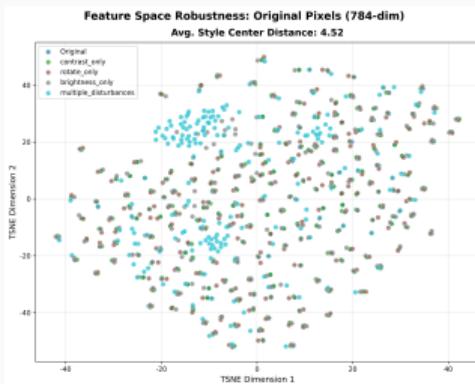
泛化能力:MNIST 数据量下的结论

测试集	准确率	平均 Recall
Contrast	0.958	0.960
Rotate	0.958	0.960
Brightness	0.958	0.960
Multiple Disturbances	0.916	0.922

备注: 对于多个扰动测试集, 尽管准确率有所下降 (0.916), 但大部分类别的 Recall 值较高, 尤其是数字"0"、"6" 和"8" 的 Recall 均维持在较高水平。少数类别 (如"1" 和"7") 的 Recall 较低, 表明其泛化能力受到了影响。

泛化能力: 特征提取有效性

不同特征提取方式的特征空间分布:



对不同风格测试集的泛化能力

泛化原理:

- 通关特征提取忽略与分类无关的特征因素

测试原理:

- 在测试集中引入特定扰动以评估模型的泛化能力

实现过程:

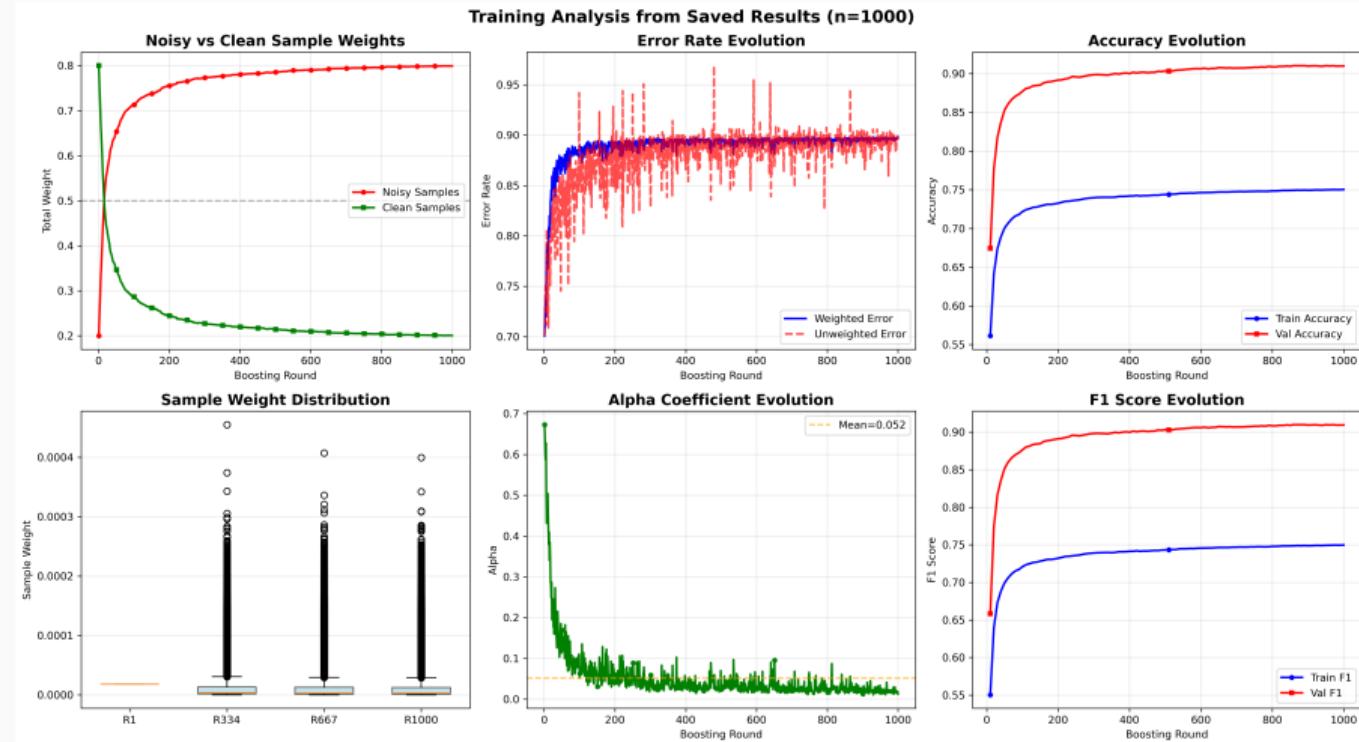
- 调整训练模型的风格参数实现不同风格

对不同风格测试集的泛化能力

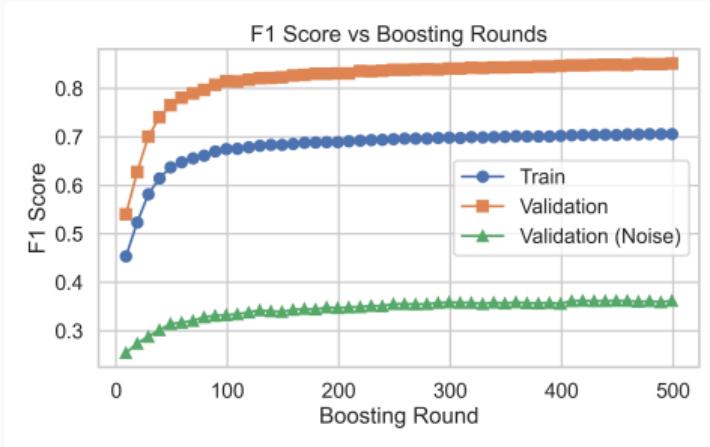
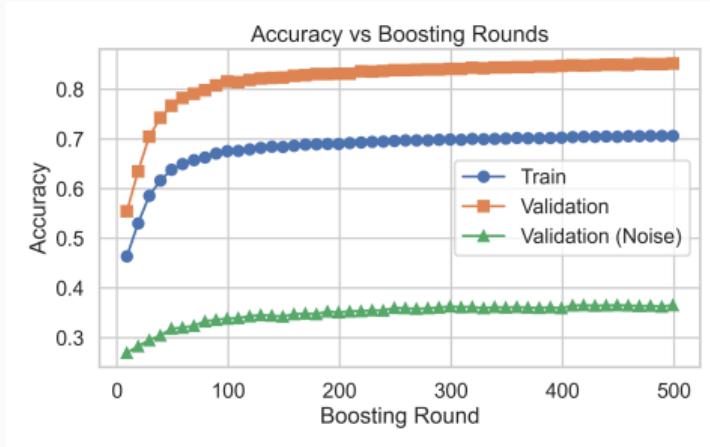
风格扰动研究分析与结论：

- 加入不同扰动后，特征提取的效果明显
- 合适的特征提取能够有效减少风格本身的影响
- 最终呈现的模型准确率与无扰动数据差距很小

鲁棒性：模型对噪声的适应能力



鲁棒性：模型对噪声的适应能力



鲁棒性: 训练模型对噪声的适应能力

噪声研究分析与结论

- 随着迭代次数增多，噪声权重增大导致后续学习器逐渐关注训练集的噪声部分
- 实际训练中，更关注噪声的这部分学习器在最终得到的模型中权重很小
- 训练集噪声对模型训练的影响相对稳定，且无噪声测试集仍呈现较高的准确率

误差来源与影响

- 样本数量少，识别结果方差大，准确率波动较大
- 人工噪声无法模拟真实的误差环境，实验对比更多体现了模型的泛化能力

总结

实验结果：

- **噪声适应能力较强**: 噪声研究显示，训练模型能够有效识别噪声并在合理迭代次数下，能够减少噪声对模型的影响，总体分析得出训练模型对噪声的适应能力较强
- **泛化能力强**: 风格扰动对模型训练的干扰不明显，数据能够直观展现模型的泛化能力强

综合评价：

- 训练模型虽然可以保证对纯净样本较高的准确率，但准确率随噪声增大而下降的现象仍然明显，训练时需要**尽量避免噪声干扰**
- 特征提取是加强泛化能力的关键，需要**选择合适的特征提取方式**强化模型的泛化能力

谢谢大家！