
分类问题视角下的 AdaBoost 算法

December 7, 2025

AdaBoost 模型结构

模型介绍

- AdaBoost 是一种典型的提升（Boosting）型集成学习框架，其核心思想是：**通过多轮训练、聚焦难样本，把一群“弱学习器”提升为一个“强学习器”。**
- 在每一轮中，AdaBoost 都会为总模型增加一个新的学习器，指导模型的弱学习器个数达到预先指定的值。
- 训练新学习器时，根据上一轮的推理结果在同一训练集上**重新分配样本权重**，使新的弱学习器更加关注上一轮中被分错或“难学”的样本。
- 各轮得到的弱学习器本身能力都比较弱，但在最后通过加权组合（加权投票或加权求和），形成一个整体性能更高、泛化能力更强的强学习器。
- AdaBoost 不限定弱学习器的具体形式（如决策树桩、小深度决策树等），因此可以看作一个**通用的、可移植的集成学习框架**。

AdaBoost 模型结构图

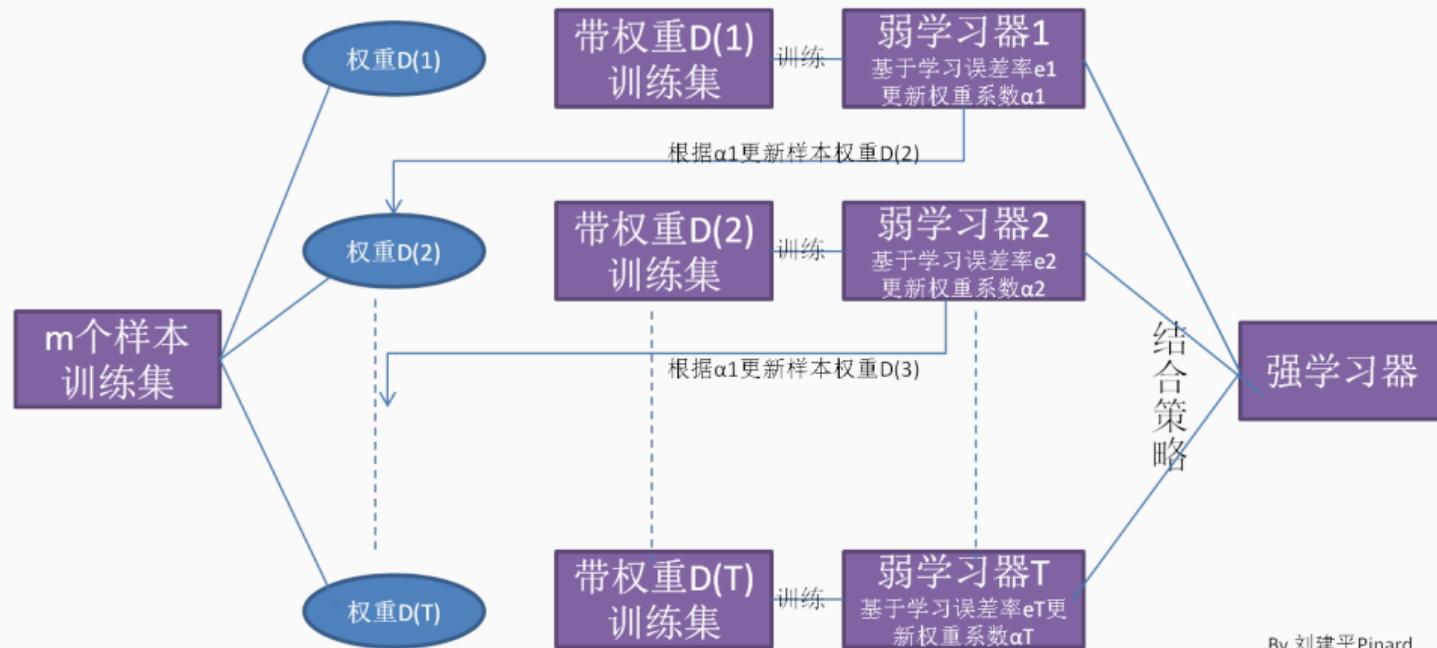


Figure 1. AdaBoost 模型结构图

AdaBoost 模型结构

计算流程

错误率计算规则

假设训练集包含 m 个样本 $\{(x_i, y_i), \dots, (x_m, y_m)\}$ 。

不失一般性地，假设现在训练已经进行到第 t 轮，将要训练第 t 个弱学习器。

记第 t 个学习器在样本 x 上的预测结果为 $h_t(x)$ 。

设训练第 t 个弱学习器所使用的样本权重为

$$D_t = \{\omega_{t1}, \dots, \omega_{tm}\}, \quad \sum_{i=1}^m \omega_{ti} = 1.$$

则第 t 轮弱学习器的加权错误率为

$$\varepsilon_t = \sum_{i=1}^m \omega_{ti} \mathbf{1}\{h_t(x_i) \neq y_i\}.$$

样本加权规则

第 t 轮 ($t = 1, \dots, T$):

1. 计算系数

$$\beta_t = \frac{\varepsilon_t}{1 - \varepsilon_t}, \quad 0 < \beta_t < 1.$$

2. 先得到更新后的未归一化权重

$$\tilde{\omega}_{t+1,i} = \omega_{ti} \beta_t^{1 - \mathbf{1}\{h_t(x_i) \neq y_i\}}, \quad i = 1, \dots, m.$$

3. 再将其归一化，得到下一轮的权重分布

$$\omega_{t+1,i} = \frac{\tilde{\omega}_{t+1,i}}{\sum_{j=1}^m \tilde{\omega}_{t+1,j}}.$$

直观理解：

$$\begin{cases} h_t(x_i) = y_i \Rightarrow \tilde{\omega}_{t+1,i} = \omega_{ti} \beta_t & (\text{分对：权重减小}) \\ h_t(x_i) \neq y_i \Rightarrow \tilde{\omega}_{t+1,i} = \omega_{ti} & (\text{分错：权重不变，归一化后相对增大}) \end{cases}$$

收敛性

AdaBoost 的训练误差界

设：

- 第 t 轮弱学习器的加权错误率为 ε_t ；
- 最终强分类器为 h_f ，其在训练分布 D 下的错误率为

$$\varepsilon = \Pr_{i \sim D} [h_f(x_i) \neq y_i].$$

AdaBoost 的训练误差界

训练误差上界

$$\varepsilon \leq 2^T \prod_{t=1}^T \sqrt{\varepsilon_t(1 - \varepsilon_t)}.$$

引入第 t 轮的“优势”(edge)：比随机猜测强的部分

$$\gamma_t = \frac{1}{2} - \varepsilon_t,$$

则上界可以改写为

$$\varepsilon \leq \prod_{t=1}^T \sqrt{1 - 4\gamma_t^2} = \exp\left(-\sum_{t=1}^T \text{KL}\left(\frac{1}{2} \parallel \frac{1}{2} - \gamma_t\right)\right) \leq \exp\left(-2 \sum_{t=1}^T \gamma_t^2\right).$$

AdaBoost 的训练误差界

特殊情形：若所有弱学习器的错误率都相同， $\varepsilon_t = \frac{1}{2} - \gamma$ ($\gamma > 0$)，则

$$\varepsilon \leq (1 - 4\gamma^2)^{T/2} = \exp(-T \cdot \text{KL}(\frac{1}{2} \parallel \frac{1}{2} - \gamma)) \leq \exp(-2T\gamma^2).$$

结论：只要每一轮的弱学习器都略好于随机猜测 ($\gamma_t > 0$)，AdaBoost 在训练集上的错误率会随轮数 T 指数级下降。

收敛性

收敛性证明

收敛性证明

引理：训练误差界受限于归一化因子之积。

$$\frac{1}{m} \sum_{i=1}^m \exp(-y_i f(x_i)) = \prod_{t=1}^T Z_t.$$

其中 $Z_t = \sum_{i=1}^m \omega_{ti} \exp(-\alpha_t y_i h_t(x_i))$ 。

证明思路：

1. 递推关系: $\omega_{t+1,i} = \frac{\omega_{ti} \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$
2. 展开得到: $\omega_{T+1,i} = \frac{1}{m \prod_{t=1}^T Z_t} \exp(-y_i \sum_{t=1}^T \alpha_t h_t(x_i))$
3. 由 $\sum \omega_{T+1,i} = 1$, 可得上述等式。
4. 由于 $\mathbf{1}\{H(x) \neq y\} \leq \exp(-y H(x))$, 故误差 $\leq \prod Z_t$ 。

收敛性证明 (续)

计算 Z_t 的极小值：

$$Z_t = \sum_{y_i=h_t(x_i)} \omega_{ti} e^{-\alpha_t} + \sum_{y_i \neq h_t(x_i)} \omega_{ti} e^{\alpha_t} = (1 - \varepsilon_t) e^{-\alpha_t} + \varepsilon_t e^{\alpha_t}$$

对 α_t 求导并令其为 0，可得最优权重：

$$\alpha_t = \frac{1}{2} \ln \frac{1 - \varepsilon_t}{\varepsilon_t}$$

代回 Z_t 表达式：

$$Z_t = 2\sqrt{\varepsilon_t(1 - \varepsilon_t)} = \sqrt{1 - 4\gamma_t^2}$$

从而得证：

$$\varepsilon_{\text{train}} \leq \prod_{t=1}^T \sqrt{1 - 4\gamma_t^2} \leq \exp(-2 \sum_{t=1}^T \gamma_t^2)$$

泛化误差

泛化误差与过拟合

- **现象：**在许多实验中观察到，即使训练误差已经降为 0，继续增加弱分类器数量 T ，测试误差不仅没有上升（过拟合），反而进一步下降。
- **传统解释失效：**传统的 VC 维理论认为模型复杂度随 T 增加，泛化界应变差。
- **间隔理论（Margin Theory）：** AdaBoost 在训练误差为 0 后，继续训练会使得样本的分类间隔（Margin）不断增大。

$$\text{margin}(x, y) = \frac{y \sum_t \alpha_t h_t(x)}{\sum_t \alpha_t}$$

- 更大的间隔意味着更强的鲁棒性和更好的泛化能力。

理论进阶

统计解释：指数损失最小化

AdaBoost 的另一种解释是：**前向分步加法模型** (Forward Stagewise Additive Modeling) 在**指数损失函数**下的优化过程。

- **加法模型:** $f(x) = \sum_{t=1}^T \alpha_t h_t(x)$
- **损失函数:** $L(y, f(x)) = \exp(-yf(x))$

性质: 指数损失是 0/1 损失的一致上界，且处处可微。

$$\mathbf{1}\{y \neq f(x)\} \leq \exp(-yf(x))$$

最小化指数损失等价于最小化分类错误率的上界。这为 AdaBoost 的权重更新规则提供了统计学依据。

多分类扩展：SAMME 算法

原始 AdaBoost (AdaBoost.M1) 主要针对二分类问题。对于 MNIST 手写数字识别 (10 分类)，需要进行扩展。

SAMME (Stagewise Additive Modeling using a Multi-class Exponential loss function) 算法调整了权重更新公式：

$$\alpha_t = \ln \frac{1 - \varepsilon_t}{\varepsilon_t} + \ln(K - 1)$$

其中 K 是类别数量 (MNIST 中 $K = 10$)。

收敛条件：只要 $\varepsilon_t < 1 - \frac{1}{K}$ (即弱分类器优于随机猜测)，则 $\alpha_t > 0$ ，算法即可收敛。

偏差-方差权衡 (Bias-Variance Tradeoff)

从误差分解的视角对比 Bagging (如随机森林) 与 Boosting (如 AdaBoost)：

- **Bagging (并行)**: 通过对训练集重采样训练多个强学习器并取平均。主要降低**方差 (Variance)**，适合高方差模型（如完全生长的决策树）。
- **Boosting (串行)**: 通过迭代修正前一轮的错误。主要降低**偏差 (Bias)**，能将高偏差的弱学习器（如决策树桩）提升为强学习器。随着迭代次数增加，方差也可能略有下降，但过度迭代会导致过拟合（方差上升）。

正则化: Shrinkage 策略

为了进一步防止过拟合，AdaBoost 常引入学习率 (Learning Rate) 参数 ν ($0 < \nu \leq 1$)：

$$f_t(x) = f_{t-1}(x) + \nu \cdot \alpha_t h_t(x)$$

- **作用:** 限制每个弱分类器的贡献，迫使学习过程更加缓慢和稳健。
- **代价:** 较小的 ν 通常意味着需要更多的迭代次数 T 才能达到同样的训练误差。
- 在实践中，这是调节模型泛化能力最重要的参数之一。

总结与展望

AdaBoost 优缺点总结

优点：

- **泛化能力强**: 在许多问题上不易过拟合 (Margin 理论)。
- **参数少**: 原始算法几乎无需调参。
- **通用性**: 可与任何弱学习器结合。

缺点：

- **对噪声敏感**: 异常值权重会被过度放大 (本次实验重点验证)。
- **串行训练**: 难以并行化, 训练速度较慢。

经典应用: Viola-Jones 人脸检测框架 (基于 Haar 特征 + AdaBoost 级联)。

任务：手写数字识别

训练流程及结果

数据集

关键代码

准确率

任务：手写数字识别

误差分析

基于 MNIST 变体的鲁棒性分析

为了评估模型的鲁棒性，我们将原始 MNIST 测试集进行不同程度的变换作为新的测试集（MNIST Variants），主要包括噪声干扰（高斯噪声、椒盐噪声）和几何变换（旋转、缩放）。

实验结果与分析：

- 对噪声敏感：** AdaBoost 在干净数据上表现优异，但随着噪声比例增加，准确率下降明显快于 Bagging 类算法（如随机森林）。
- 原因探究：** AdaBoost 的核心机制是关注“难分样本”。高噪声样本往往被视为难分样本，权重被不断放大。
- 权重偏移：** 模型过度关注这些无法正确分类的噪声点（离群点），导致决策边界发生扭曲，从而降低了对正常样本的泛化能力。

谢谢大家！