
分类问题视角下的 AdaBoost 算法

December 25, 2025

AdaBoost 模型结构

- AdaBoost 是一种典型的提升（Boosting）型集成学习框架，其核心思想是：**通过多轮训练、聚焦难样本，把一群“弱学习器”提升为一个“强学习器”。**
- 在每一轮中，AdaBoost 都会为总模型增加一个新的学习器，直到模型的弱学习器个数达到预先指定的值。
- 训练新学习器时，根据上一轮的推理结果在同一训练集上**重新分配样本权重**，使新的弱学习器更加关注上一轮中被分错或“难学”的样本。
- 各轮得到的弱学习器本身能力都比较弱，但在最后通过加权组合（加权投票或加权求和），形成一个整体性能更高、泛化能力更强的强学习器。
- AdaBoost 不限定弱学习器的具体形式（如决策树桩、小深度决策树等），因此可以看作一个**通用的、可移植的集成学习框架**。

模型结构图

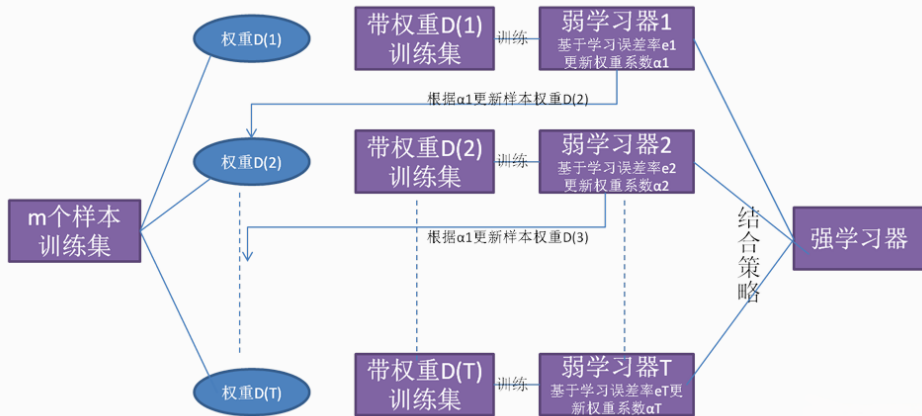


Figure 1. AdaBoost 模型结构图

假设训练集包含 m 个样本 $\{(x_i, y_i), \dots, (x_m, y_m)\}$ 。

第 1 个学习器直接由初始权重的样本训练即可

不失一般性地，假设现在训练已经进行到第 t 轮。 ($t = 2, \dots, T$)

记第 $t - 1$ 个学习器在样本 x 上的预测结果为 $h_{t-1}(x)$ 。

设训练第 $t - 1$ 个弱学习器所使用的样本权重为

$$D_t = \{\omega_{t-1,1}, \dots, \omega_{t-1,m}\}, \quad \sum_{i=1}^m \omega_{t-1,i} = 1.$$

则第 $t - 1$ 轮弱学习器的加权错误率为

$$\varepsilon_{t-1} = \sum_{i=1}^m \omega_{t-1,i} \mathbf{1}\{h_{t-1}(x_i) \neq y_i\}.$$

第 $t - 1$ 个弱学习器的投票权重为

$$\alpha_{t-1} = \frac{1}{2} \left(\frac{1 - \varepsilon_{t-1}}{\varepsilon_{t-1}} \right)$$

模型计算流程：样本权重更新

1. 计算系数

$$\beta_{t-1} = \frac{\varepsilon_{t-1}}{1 - \varepsilon_{t-1}}, \quad 0 < \beta_{t-1} < 1.$$

2. 先得到更新后的未归一化权重

$$\tilde{\omega}_{t,i} = \omega_{t-1,i} \beta_{t-1}^{1 - \mathbf{1}\{h_{t-1}(x_i) \neq y_i\}}, \quad i = 1, \dots, m.$$

3. 再将其归一化，得到第 t 轮的权重分布

$$\omega_{t,i} = \frac{\tilde{\omega}_{t,i}}{\sum_{j=1}^m \tilde{\omega}_{t,j}}.$$

4. 由得到的新样本权重训练集训练得到第 t 个弱学习器

第 t 轮：直观理解：

$$\begin{cases} h_{t-1}(x_i) = y_i \Rightarrow \tilde{\omega}_{t,i} = \omega_{t-1,i} \beta_{t-1} & (\text{分对：权重减小}) \\ h_{t-1}(x_i) \neq y_i \Rightarrow \tilde{\omega}_{t,i} = \omega_{t-1,i} & (\text{分错：权重不变，归一化后相对增大}) \end{cases}$$

这意味这模型会不断给难以分类的样本点增加权重，而这些难分类的点可能是数据中的噪声/离群点，可能导致模型在中后期过拟合。

收敛性

设:

- 第 t 轮弱学习器的加权错误率为 ε_t ;
- 最终强分类器为 h_f , 其在训练分布 D 下的错误率为

$$\varepsilon = \Pr_{i \sim D}[h_f(x_i) \neq y_i].$$

训练误差上界

$$\varepsilon \leq 2^T \prod_{t=1}^T \sqrt{\varepsilon_t(1 - \varepsilon_t)}.$$

引入第 t 轮的“优势” (edge) : 比随机猜测强的部分

$$\gamma_t = \frac{1}{2} - \varepsilon_t,$$

则上界可以改写为

$$\varepsilon \leq \prod_{t=1}^T \sqrt{1 - 4\gamma_t^2} = \exp\left(-\sum_{t=1}^T \text{KL}\left(\frac{1}{2} \parallel \frac{1}{2} - \gamma_t\right)\right) \leq \exp\left(-2 \sum_{t=1}^T \gamma_t^2\right).$$

特殊情形：若所有弱学习器的错误率都相同， $\varepsilon_t = \frac{1}{2} - \gamma$ ($\gamma > 0$)，则

$$\varepsilon \leq (1 - 4\gamma^2)^{T/2} = \exp(-T \cdot \text{KL}(\frac{1}{2} \parallel \frac{1}{2} - \gamma)) \leq \exp(-2T\gamma^2).$$

结论：只要每一轮的弱学习器都略好于随机猜测 ($\gamma_t > 0$)，AdaBoost 在训练集上的错误率会随轮数 T **指数级下降**。

收敛性证明

引理： 训练误差界受限于归一化因子之积。

$$\frac{1}{m} \sum_{i=1}^m \exp(-y_i f(x_i)) = \prod_{t=1}^T Z_t.$$

$$Z_t = \sum_{y_i=h_t(x_i)} \omega_{ti} e^{-\alpha_t} + \sum_{y_i \neq h_t(x_i)} \omega_{ti} e^{\alpha_t} = (1 - \varepsilon_t) e^{-\alpha_t} + \varepsilon_t e^{\alpha_t}$$

通过求导计算得到 Z_t 的极小值：

$$Z_t = 2\sqrt{\varepsilon_t(1 - \varepsilon_t)} = \sqrt{1 - 4\gamma_t^2}$$

从而得证：

$$\varepsilon_{train} \leq \prod_{t=1}^T \sqrt{1 - 4\gamma_t^2} = \exp\left(-\sum_{t=1}^T \text{KL}\left(\frac{1}{2} \parallel \frac{1}{2} - \gamma_t\right)\right) \leq \exp\left(-2\sum_{t=1}^T \gamma_t^2\right).$$

总结与展望

优点：

- **泛化能力强：**在许多问题上不易过拟合（Margin 理论）。
- **参数少：**原始算法几乎无需调参。
- **通用性：**可与任何弱学习器结合。

缺点：

- **对噪声敏感：**异常值权重会被过度放大（本次实验重点验证）。
- **串行训练：**难以并行化，训练速度较慢。

经典应用： Viola-Jones 人脸检测框架（基于 Haar 特征 + AdaBoost 级联）。

任务：手写数字识别

核心目标:

训练一个 AdaBoost 分类器, 对手写数字图片进行分类。

这是一个多分类（十类）问题。

数据集:

- 使用 MNIST 数据集，按照 8：2 切分训练集和测试集，
- 在 MNIST 测试集和课程提供的手写图片两组数据上分别测试。

数据预处理:

- 所有图片转化为黑底白字
- 按照包含该数字的最小正方形进行切割
- 使用 `cv2.resize` 方法将图片缩放至 20x20
- 将数字图片嵌入到 28x28 的纯黑色背景

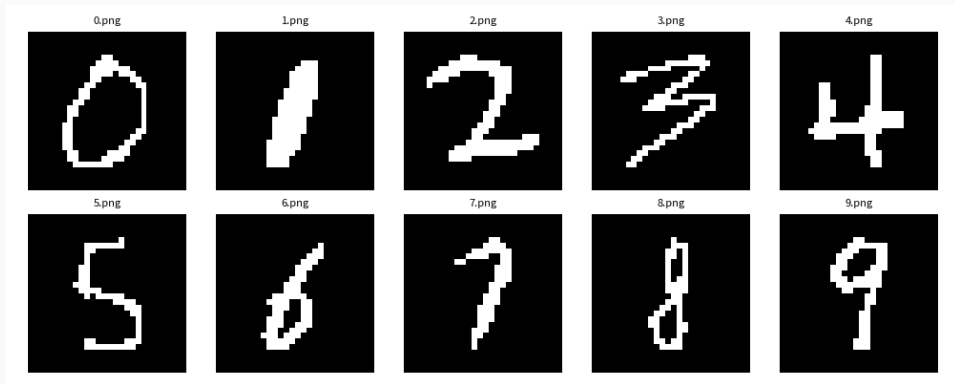


Figure 2.预处理后数据示意图

特征提取方法:

- 原始图片, reshape 为 (784,) 一维向量
- HOG
- Hu 不变矩

目标:

- 对比原始特征和提取特征的聚类效果, 证明提取特征的有效性
- 提升风格迁移泛化能力

聚类与可视化:

- 对不同风格数据集的特征进行聚类 and 可视化, 呈现分布差异

使用 'sklearn.ensemble.AdaBoostClassifier' 实现的 AdaBoost 分类器

```
clf = AdaBoostClassifier(  
    estimator=base,  
    n_estimators=model_cfg["n_estimators"],  
    learning_rate=model_cfg["learning_rate"],  
    random_state=model_cfg["random_state"],  
)
```

Figure 3.sklearn AdaBoost 分类器实例构建

关键代码

```
(machinelearning) flyingbucket@H3C-R5300-G5-A30:~/adaboost$ python main.py --config configs/main_original.json
[Workflow] experiment dir created: experiments/main_original
[Data] Downloading MNIST...
[Data] No noise added.
[MODEL] Using original AdaBoost without BoostMonitor
[Workflow] Training Started...
[Workflow] Training Finished...
[Workflow] Uncompressed model joblib saved to : experiments/main_original/results/model.joblib
[Workflow] compressed and saved to : experiments/main_original/results/model.joblib.xz
[Workflow] compressed model joblib saved to : experiments/main_original/results/model.joblib.xz
[Data] Loading course dataset from: test_data

===Scores on test data of MNIST===

=== Evaluation ===
Accuracy:      0.8727
Precision_macro:0.8758
Recall_macro:  0.8719
F1_macro:      0.8723

===Scores on test data of corse data===

=== Evaluation ===
Accuracy:      0.4000
Precision_macro:0.2083
Recall_macro:  0.4000
F1_macro:      0.2567
```

Figure 4.实验主入口示例

任务：手写数字识别

实验数据展示

参数	值
max_depth	2
max_features	0.2
criterion	entropy
random_state	42
n_estimators	1000
learning_rate	0.5

Table 1.训练参数

数据集	准确率	精度 (宏平均)	召回率 (宏平均)	F1 值 (宏平均)
MNIST	0.8727	0.8758	0.8719	0.8723
课程数据集	0.4	0.2083	0.4	0.2567

Table 2.模型在 MNIST 和课程数据集上的测试结果

数据集	准确率	精度 (宏平均)	召回率 (宏平均)	F1 值 (宏平均)
MNIST	0.5051	0.4921	0.4961	0.4904
课程数据集	0.2	0.15	0.2	0.1667

Table 3.模型在 MNIST 和课程数据集上的测试结果

参数	值
orientations	9
pixels_per_cell	[2, 2]
cells_per_block	[2, 2]


Table 4.HOG 特征提取参数

数据集	准确率	精度 (宏平均)	召回率 (宏平均)	F1 值 (宏平均)
MNIST	0.9356	0.93596	0.93515	0.93536
课程数据集	0.7	0.5833	0.7	0.6167


Table 5.模型在 MNIST 和课程数据集上的测试结果

理想模型数据展示

Accuracy Evolution



F1 Score Evolution






任务：手写数字识别

鲁棒性与误差分析

特征提取有效性

不同特征提取方式的特征空间分布：



训练模型对噪声的适应能力



由于原始数据噪声较少，通过人为添加噪声探究其对 ababoost 拟合效果的影响
(特征与噪声在学习器中的权重图，title 弱学习器的分类权重)

训练模型对噪声的适应能力

(最终得到的加权学习器的权重图, title 最终模型的权重)

(噪声环境对准确率的影响图,title 噪声环境下分辨优质样本的准确率)

训练模型对噪声的适应能力



噪声研究分析与结论

- 随着迭代次数增多，噪声权重增大导致后续学习器逐渐关注训练集的噪声部分
- 实际训练中，更关注噪声的这部分学习器在最终得到的模型中权重很小
- 训练集噪声对模型训练的影响相对稳定，且无噪声测试集仍呈现较高的准确率

对不同风格测试集的泛化能力

泛化原理:

- 通关特征提取忽略与分类无关的特征因素




测试原理:

- 在测试集中引入特定扰动以评估模型的泛化能力

实现过程:

- 调整训练模型的风格参数实现不同风格

对不同风格测试集的泛化能力



风格扰动研究分析与结论:

- 加入不同扰动后，特征提取的效果明显
- 合适的特征提取能够有效减少风格本身的影响
- 最终呈现的模型准确率与无扰动数据差距很小

误差来源与影响

- 样本数量少，识别结果方差大，准确率波动较大
- 特征提取展示降维较多，数据展示较为单一
- 人工噪声无法模拟真实的误差环境, 实验对比更多体现了模型的泛化能力

基于 MNIST 变体的鲁棒性分析

实验结果:

- **噪声适应能力较强**: 噪声研究显示, 训练模型能够有效识别噪声并在合理迭代次数下, 能够减少噪声对模型的影响, 总体分析得出训练模型对噪声的适应能力较强
- **泛化能力强**: 风格扰动对模型训练的干扰不明显, 数据能够直观展现模型的泛化能力强

综合评价:

- 训练模型虽然可以保证对纯净样本较高的准确率, 但准确率随噪声增大而下降的现象仍然明显, 训练时需要**尽量避免噪声干扰**
- 特征提取是加强泛化能力的关键, 需要**选择合适的特征提取方式**强化模型的泛化能力

谢谢大家！